Highlights

-

a

[a], ,

Abstract

Keywords:

1. Introduction（引言）

对流传热广泛存在于电子器件散热、换热设备、建筑热环境与能源系统中。其速度场与温度场由一组控制参数决定，参数变化会改变流动结构、边界层分布和壁面换热。设计优化、参数分析和多工况预测都需要在参数空间内反复求解耦合的非线性控制方程，高保真数值方法对每个参数点单独求解，所需计算量随查询次数线性增长。参数化降阶模型以低维表示近似高维离散系统，是这类多查询计算的主要途径 [1]。

本征正交分解（Proper Orthogonal Decomposition，POD）从高保真快照中提取主导空间模态 [2, 3]；将控制方程投影到 POD 试探空间，即得到 POD-Galerkin 降阶模型。该方法已用于非定常热混合 [4]、参数化 Boussinesq 流动 [5]、Rayleigh–Bénard 对流 [6, 7] 和液态金属浮力流动 [8] 等流热耦合问题。降阶解始终位于试探空间之内，试探空间对目标解的最佳逼近误差构成降阶精度的下限，无论展开系数由插值、回归还是物理方程确定。在宽参数范围内，流动结构随参数显著变化，有限快照张成的空间难以表示未采样参数处的解，这一下限成为限制精度的主要因素。

改进试探空间是提高参数化降阶精度的直接途径。Amsallem 等 [9] 按解状态构造局部降阶基。Hay 等 [10, 11] 利用 POD 对参数的灵敏度扩展降阶基，提高了偏离采样参数处的表示精度。对稳态问题，训练点处解的参数灵敏度可由离散稳态方程直接求得，复用该点雅可比的分解，不需要额外的高保真工况。由快照与灵敏度共同张成的灵敏度增广空间同时包含训练点处的解及其一阶参数变化，在此空间上做 Galerkin 投影即得到灵敏度增广 POD-Galerkin 方法（SA-PODG）。该空间与查询参数无关；快照稀疏或查询点远离训练点时，解中仍有该空间未能表示的余量。

神经网络为参数相关的流热场表示提供了另一类工具。参数化物理信息神经网络（PINNs）以控制方程残差训练网络，已用于方腔自然对流 [12]、多参数瞬态热问题 [13] 和高精度自然对流求解 [14]；NeuroSEM 将 PINNs 与谱元求解器耦合，由两者分担不同子域或状态变量 [15]。在降阶框架中，一

类方法用神经网络学习参数到 POD 系数的映射 [16, 17]，或在系数学习中引入降阶方程残差 [18]，重构解仍处于预设的试探空间之内。另一类方法让神经网络参与表示空间的构造：深度自编码器建立非线性解流形 [19, 20]，神经网络增广的投影降阶方法学习非线性近似流形 [21]，自编码器与 Galerkin 投影结合以修正降阶表示 [22]，深度正交分解则由网络构造随参数变化的局部基 [23]。可微分 PDE 约束层由网络提供一组函数，再由满足控制方程的优化确定其组合系数 [24]，体现了网络提供表示、物理方程确定解的混合思路。

本文沿这一思路，用神经网络补充 SA-PODG 基础空间之外的方向。网络以训练快照的场值为监督，预测写成一组候选场的线性读出；候选场张成的正是网络经最后一层读出偏置所能到达的输出变化空间。在查询参数处，候选场去除基础空间分量并正交化，构成神经互补空间，与基础空间一起组成增广试探空间；降阶解由有效残差在增广空间上的 Galerkin 投影确定，辅助温度场在闭合中同步求解。网络只提供空间方向，最终状态由控制方程决定。增广空间包含基础空间，其最佳逼近误差不高于 SA-PODG；互补空间对基础空间解余量的捕获率，以及实际误差与最佳逼近误差之比，共同决定增广后的求解误差。

本文将上述方法称为神经增广 POD–Galerkin 方法（Neural-Enriched POD–Galerkin，NE-PODG），并以二维侧壁差分加热方腔 [25] 在宽 Ra–Pr 参数范围内的稳态自然对流为算例进行验证。主要工作包括：

1. 提出 NE-PODG：场值监督训练的网络在查询参数处为 SA-PODG 提供互补空间，降阶解由增广空间上的 Galerkin 闭合确定；
2. 建立余量捕获率与闭合放大系数的误差关系，并通过训练与未训练网络的对照，说明场值监督训练带来精度提升的来源；
3. 在少量快照下，与 POD–Galerkin 和 SA-PODG 比较参数域内插与高 Rayleigh 数外推工况的速度场、温度场与 Nusselt 数预测精度，并分析增广维数与快照预算对精度的影响。

第 2 节给出问题描述、全阶离散、NE-PODG 的构造与误差关系以及数值设置；第 3 节报告精度、流场与传热预测、增广机制、增广维数与快照预算的结果；第 4 节总结全文。

2. Methodology（方法）

2.1. Problem description（问题描述）

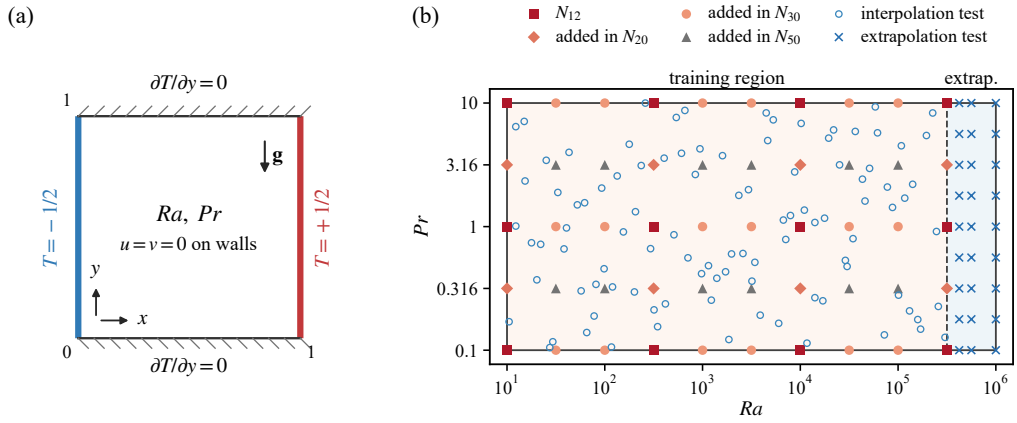


Figure 1: (a) 侧壁差分加热方腔的物理模型与边界条件；(b) 参数域、各快照预算的训练点及内插、外推测试工况。

2.2. Discrete problem and base space（离散问题与基础空间）

2.3. Value-supervised neural candidate fields（场值监督的神经候选场）

2.4. Complementary space construction and Galerkin closure（互补空间构造与 *Galerkin* 闭合）

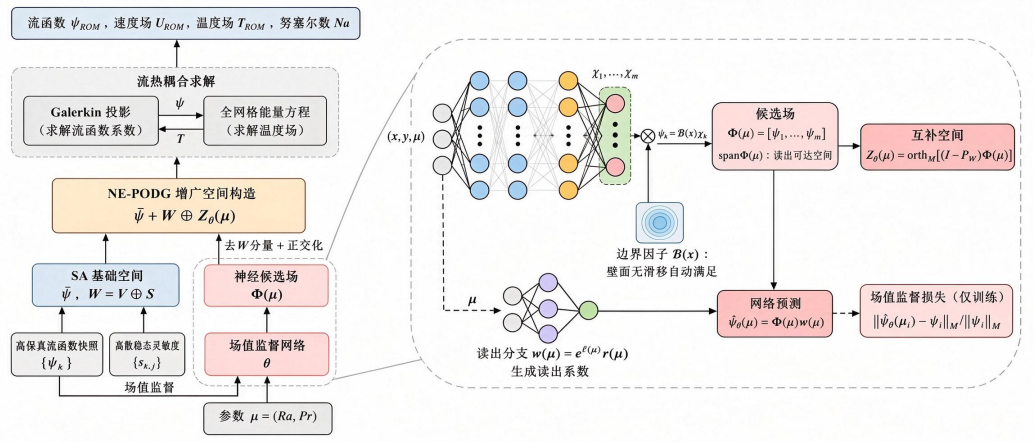


Figure 2: NE-PODG 的总体框架。

2.5. Approximation and error characterization（逼近与误差刻画）

2.6. Numerical implementation and verification（数值实现与验证）

高保真解. 训练快照、灵敏度与参考解都在 128×128 的向壁加密 MAC 网格上求得，降阶闭合也在这一离散上进行。$Pr = 0.71$ 时平均 Nusselt 数与 Chebyshev 谱方法基准解的相对差不超过 0.01%；求解设置、基准对照与网格收敛见附录 Appendix A.1。

训练与测试数据. 参数域为 $Ra \in [10, 10^6]$、$Pr \in [0.1, 10]$，训练快照全部取自 $Ra \leq 3.16 \times 10^5$ 的训练区。训练池由训练区内 $\log_{10} Ra$、$\log_{10} Pr$ 间隔 0.5 的规则网格组成，共 50 个参数点（10 档 $Ra \times 5$ 档 Pr）。快照预算取训练池的四个规则子集：N_{12} 取 $Ra = 10$、316、1.00×10^4、3.16×10^5 与 $Pr = 0.1$、1、10；N_{20} 在 N_{12} 上将 Pr 加密到 5 档；N_{30} 在 N_{12} 上将 Ra 加密到 10 档；N_{50} 为整个训练池。四者满足 $N_{12} \subset N_{20} \subset N_{50}$ 与 $N_{12} \subset N_{30} \subset N_{50}$。预算内每个训练点提供一个快照及其对 $\log_{10} Ra$、$\log_{10} Pr$ 的稳态灵敏度。测试工况只用于评价：内插测试为训练区 $(\log_{10} Ra, \log_{10} Pr) \in [1, 5.5] \times [-1, 1]$ 上的 100 个拉丁超立方取样点，在两个对数坐标上同时与某一训练池点相差小于 0.05 的取样点不用；外推测试取 $Ra = 4.22 \times 10^5$、5.62×10^5、1.00×10^6 与 $\log_{10} Pr = -1, -0.75, \ldots, 1$ 的组合，共 27 个工况。各组参数点见图 1(b)。

误差度量. 速度误差取第 2.5 节定义的 M 范数相对误差 e。温度误差为 $e_T = \|T_r - T^\star\|_{L^2} / \|T^\star\|_{L^2}$，平均 Nusselt 数误差为 $|\overline{Nu}_r / \overline{Nu}^\star - 1|$，上标 $\star$ 表示同一离散上的高保真解。内插与外推工况分别统计各误差的中位数与最大值。

计算设置. 网络、训练、空间构造与闭合的设置列于表 1。POD–Galerkin、SA-PODG 与 NE-PODG 使用同一组训练快照、同一闭合求解器与同一初值，SA-PODG 与 NE-PODG 另使用相同的稳态灵敏度；三者的差别只在试探空间。主要结果使用一个训练种子；N_{12} 与 N_{50} 另用两个种子训练，用于评价结果对网络初始化的依赖。

Table 1: NE-PODG 的计算设置。

类别	项目	设置
网络	输入	$(2x-1, 2y-1, \eta)$，$\eta = \big((\log_{10} Ra - 3.25)/2.25,\ \log_{10} Pr\big)$
	主干	5 层 × 128，tanh，输出 $m = 128$ 个原始场
	读出分支	r：2 层 × 64；ℓ：2 层 × 32；tanh
	容许映射	$\mathcal{B} = 256\, x^2(1-x)^2 y^2(1-y)^2$
训练	幅值预拟合	只训练 ℓ；Adam，学习率 10^{-2}，2000 步
	全参数训练	Adam，学习率 10^{-3}，3×10^4 步，在 1/3、2/3 步数处各降为 1/10
	批量	每步 8 个训练工况，全部 129^2 个网格角点
	种子	1234（N_{12}、N_{50} 另取 1、2）
空间构造	秩容差	$\delta_V = \delta_E = 10^{-8}$，$\tau = 10^{-6}$
闭合	非线性求解	Levenberg–Marquardt，$\epsilon_g = 10^{-10}$，$\epsilon_c = 10^{-12}$
	初值	训练点 POD 系数在 η 上的薄板样条插值，其余系数取 0
环境	硬件	Intel Core i5-14600KF，NVIDIA GeForce RTX 5060 Ti
	软件	PyTorch 2.8（CUDA 12.8），cuDSS（nvmath-python 1.0）

3. Results and discussion（结果与讨论）

3.1. Accuracy across the parameter domain（参数域上的精度）

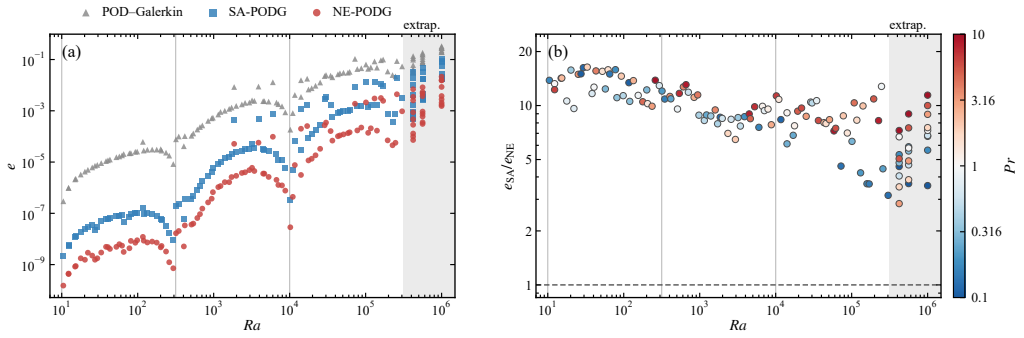


Figure 3: 快照预算 N_{12} 下全部测试工况的 (a) 三种方法的速度误差 e 与 (b) SA-PODG 与 NE-PODG 的误差之比 $e_{\mathrm{SA}}/e_{\mathrm{NE}}$（颜色表示 Pr）随 Ra 的分布。灰色竖线为训练快照所在的 Ra，阴影为外推区。

Table 2: 快照预算 N_{12} 下三种方法的误差。

误差汇总（待填）：N_{12}，内插/外推，POD–Galerkin、SA-PODG、NE-PODG 的速度场、温度场与平均 Nu 误差的中位数与最大值。

3.2. *Flow-field reconstruction and heat-transfer predictions*（流场重构与传热量预测）

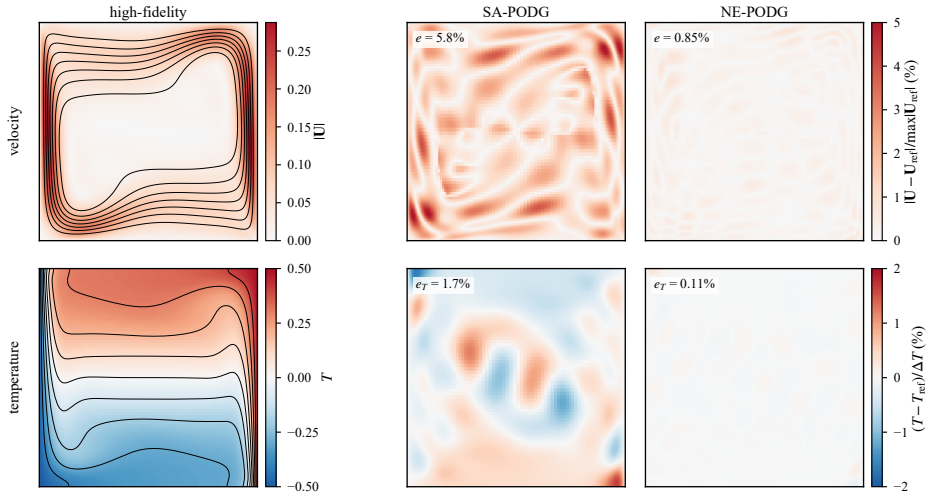


Figure 4: 快照预算 N_{12} 下外推工况 $Ra = 10^6$、$Pr = 0.562$ 的高保真速度大小（附流线）与温度（附等温线），以及 SA-PODG 与 NE-PODG 的速度误差 $|\mathbf{U} - \mathbf{U}_{\mathrm{ref}}| / \max |\mathbf{U}_{\mathrm{ref}}|$ 与温度误差 $(T - T_{\mathrm{ref}})/\Delta T$，超出色标范围的取端色。各图左上角为该方法的速度误差 e 与温度误差 e_T。

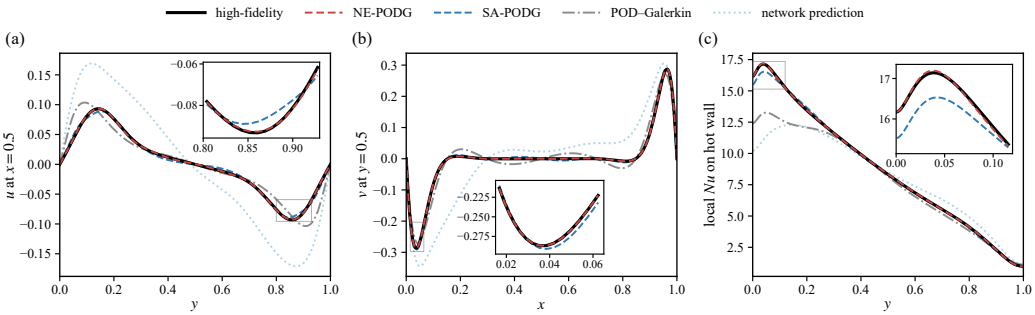


Figure 5: 快照预算 N_{12} 下外推工况 $Ra = 10^6$、$Pr = 0.562$ 的 (a) $x = 0.5$ 处水平速度 u 沿 y 的分布、(b) $y = 0.5$ 处竖直速度 v 沿 x 的分布与 (c) 热壁局部 Nusselt 数。网络预测为网络输出 $\hat{\psi}_\theta = \Phi_\theta w_\theta$ 及由其速度求得的温度；小图为方框区域的放大。

3.3. *Contribution and accuracy mechanism of neural enrichment*（神经增广的贡献与精度机制）

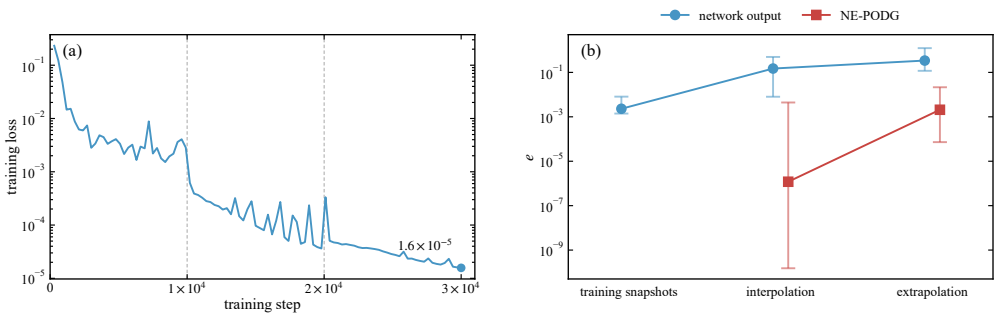


Figure 6: 快照预算 N_{12} 下的网络。(a) 训练损失，虚线处学习率降为 1/10；(b) 网络直接输出 $\hat{\psi}_\theta = \Phi_\theta w_\theta$ 与 NE-PODG 在训练快照、内插与外推工况上的速度误差 e，点为中位数，竖线为最小值到最大值。

Table 3: 快照预算 N_{12} 下网络直接输出 $\hat{\psi}_\theta = \Phi_\theta w_\theta$ 与 NE-PODG 的误差（%，中位数 / 最大值）。训练快照、内插与外推工况分别为 12、100、27 个；网络直接输出的温度由其速度在全网格上求解能量方程得到。

工况	方法	速度 e	温度 e_T	平均 Nu
训练快照	网络输出	0.23 / 0.81	0.0062 / 0.28	3.8×10^{-4} / 0.033
内插	网络输出	14.9 / 49.6	2.4 / 37.7	1.07 / 19.3
	NE-PODG	1.2×10^{-4} / 0.44	1.6×10^{-6} / 0.057	2.8×10^{-8} / 0.0052
外推	网络输出	34.1 / 124	27.8 / 52.3	1.96 / 11.3
	NE-PODG	0.21 / 2.1	0.022 / 0.40	1.1×10^{-3} / 0.083

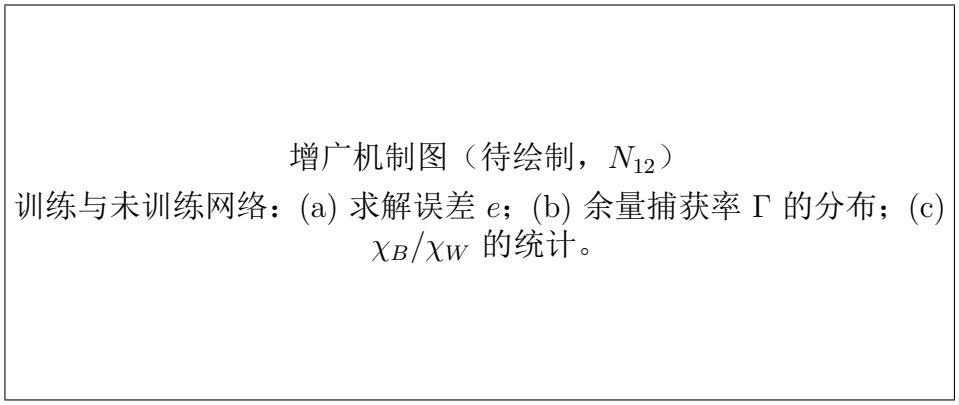


Figure 7: 训练与未训练网络的求解误差、余量捕获率与闭合放大系数之比。

3.4. Influence of enrichment dimension（增广维数的影响）

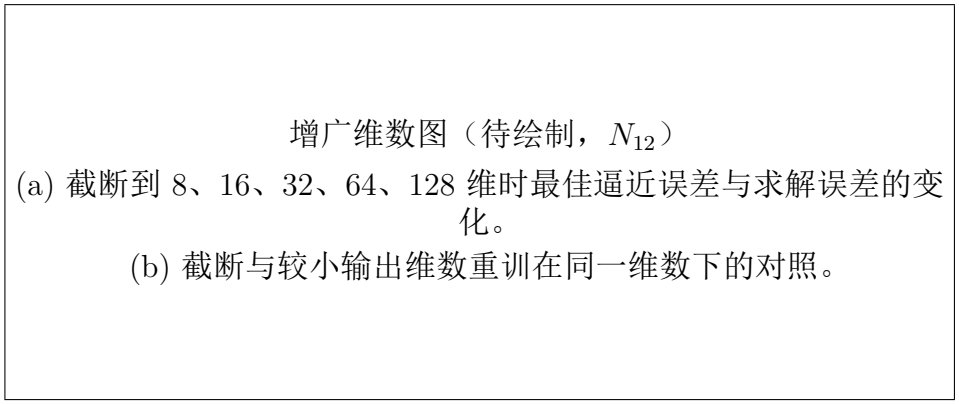


Figure 8: 精度随增广维数的变化。

3.5. Influence of snapshot budget（快照预算的影响）

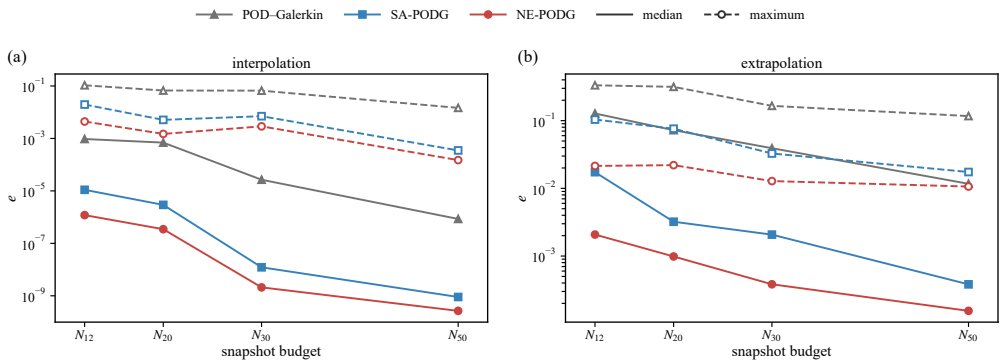


Figure 9: (a) 内插与 (b) 外推工况上三种方法速度误差的中位数（实线）与最大值（虚线）随快照预算的变化。

Table 4: 四档快照预算下三种方法的误差汇总。

误差汇总（待填）：N_{12}、N_{20}、N_{30}、N_{50} × 内插/外推，三种方法的温度场与平均 Nu 误差中位数（速度误差见图 9）；N_{12}、N_{50} 三个训练种子的范围。

4. Conclusions（结论）

Appendix A. Numerical discretization and solution details（数值离散与求解细节）

Appendix A.1. High-fidelity solution and verification（高保真求解与验证）

两个方向各取 128 个单元，节点 $x_i = \frac{1}{2}\big[1+\tanh\big(s(2i/128-1)\big)/\tanh s\big]$，$s=2$，向壁面加密。稳态离散方程用 Newton 法求解：雅可比解析组装，线性化方程在 GPU 上以双精度直接法求解；Newton 步长低于 $10^{-8}\max(1,\|q\|_\infty)$ 时收敛，q 为流函数与温度的全部未知量。各工况沿 $\log_{10} Ra$ 延拓，以前一参数点的解为初值。

表 A.1 给出 $Pr = 0.71$ 时平均 Nusselt 数与基准解的对照，本文结果与 Chebyshev 谱方法解 [26, 27] 的相对差不超过 0.01%。$Ra = 10^6$ 时 128、256、512 网格的平均 Nusselt 数分别为 8.82534、8.82523、8.82521。在整个参数域上（$Pr = 0.1$、1、10，$Ra = 10$–10^6），与 512 网格相比，平均 Nusselt 数的相对差不超过 0.02%，流函数最大值与中线速度峰值不超过 0.07%，壁面局部 Nusselt 数峰值不超过 0.47%（$Ra = 10^6$，$Pr = 0.1$）。

Table A.1: $Pr = 0.71$ 时平均 Nusselt 数与基准解的对照。

Ra	本文	文献 [25]	文献 [26]	文献 [27]
10^3	1.1178	1.117	1.1178	–
10^4	2.2448	2.238	2.245	–
10^5	4.5219	4.509	4.522	–
10^6	8.8253	8.817	8.825	8.8252

Appendix B. Supplementary numerical results（补充数值结果）

References

[1] P. Benner, S. Gugercin, K. Willcox, A survey of projection-based model reduction methods for parametric dynamical systems, SIAM Review 57 (4) (2015) 483–531. doi:10.1137/130932715.

[2] L. Sirovich, Turbulence and the dynamics of coherent structures. I. Coherent structures, Quarterly of Applied Mathematics 45 (3) (1987) 561–571. doi:10.1090/qam/910462.

[3] G. Berkooz, P. Holmes, J. L. Lumley, The proper orthogonal decomposition in the analysis of turbulent flows, Annual Review of Fluid Mechanics 25 (1993) 539–575. doi:10.1146/annurev.fl.25.010193.002543.

[4] S. Georgaka, G. Stabile, G. Rozza, M. J. Bluck, Parametric POD-Galerkin model order reduction for unsteady-state heat transfer problems, Communications in Computational Physics 27 (1) (2020) 1–32. doi:10.4208/cicp.OA-2018-0207.

[5] D. J. Knezevic, N.-C. Nguyen, A. T. Patera, Reduced basis approximation and a posteriori error estimation for the parametrized unsteady Boussinesq equations, Mathematical Models and Methods in Applied Sciences 21 (7) (2011) 1415–1442. doi:10.1142/S0218202511005441.

[6] W. Cai, H. Ma, Y. Wang, et al., Development of POD reduced-order model and its closure scheme for 2D Rayleigh–Bénard convection, Applied Mathematical Modelling 66 (2019) 562–575. doi:10.1016/j.apm.2018.09.031.

[7] K. Chand, H. Rosenberger, B. Sanderse, A pressure-free long-time stable reduced-order model for two-dimensional Rayleigh–Bénard convection, Chaos 34 (2) (2024) 023135. doi:10.1063/5.0168857.

[8] S. K. Star, G. Stabile, G. Rozza, J. Degroote, A POD-Galerkin reduced order model of a turbulent convective buoyant flow of sodium over a backward-facing step, Applied Mathematical Modelling 89 (2021) 486–503. doi:10.1016/j.apm.2020.07.029.

[9] D. Amsallem, M. J. Zahr, C. Farhat, Nonlinear model order reduction based on local reduced-order bases, International Journal for Numerical Methods in Engineering 92 (10) (2012) 891–916. doi:10.1002/nme.4371.

[10] A. Hay, J. T. Borggaard, D. Pelletier, Local improvements to reduced-order models using sensitivity analysis of the proper orthogonal decomposition, Journal of Fluid Mechanics 629 (2009) 41–72. doi:10.1017/S0022112009006363.

[11] A. Hay, J. Borggaard, I. Akhtar, D. Pelletier, Reduced-order models for parameter dependent geometries based on shape sensitivity analysis, Journal of Computational Physics 229 (4) (2010) 1327–1352. doi:10.1016/j.jcp.2009.10.033.

[12] S. Ye, J. Huang, Z. Zhang, Y. Wang, C. Huang, Direct numerical simulation of natural convection based on parameter-input physics-informed neural networks, International Journal of Heat and Mass Transfer 236 (2025) 126379. doi:10.1016/j.ijheatmasstransfer.2024.126379.

[13] M. Gholampour, Z. Hashemi, M. C. Wu, et al., Parameterized physics-informed neural networks for a transient thermal problem: A pure physics-driven approach, International Communications in Heat and Mass Transfer 159 (2024) 108330. doi:10.1016/j.icheatmasstransfer.2024.108330.

[14] P. Cui, M. Yu, W. Liu, et al., A comprehensive PINN method with hybrid Fourier feature for high-precision natural convection solution, Energy 346 (2026) 140302. doi:10.1016/j.energy.2026.140302.

[15] K. Shukla, Z. Zou, C. H. Chan, et al., NeuroSEM: A hybrid framework for simulating multiphysics problems by coupling PINNs and spectral elements, Computer Methods in Applied Mechanics and Engineering 433 (2025) 117498. doi:10.1016/j.cma.2024.117498.

[16] J. S. Hesthaven, S. Ubbiali, Non-intrusive reduced order modeling of nonlinear problems using neural networks, Journal of Computational Physics 363 (2018) 55–78. doi:10.1016/j.jcp.2018.02.037.

[17] P. Weder, M. Kast, F. Henríquez, et al., Galerkin neural network-POD for acoustic and electromagnetic wave propagation in parametric domains, Advances in Computational Mathematics 51 (2025) 37. doi:10.1007/s10444-025-10245-9.

[18] W. Chen, Q. Wang, J. S. Hesthaven, et al., Physics-informed machine learning for reduced-order modeling of nonlinear problems, Journal of Computational Physics 446 (2021) 110666. doi:10.1016/j.jcp.2021.110666.

[19] K. Lee, K. T. Carlberg, Model reduction of dynamical systems on nonlinear manifolds using deep convolutional autoencoders, Journal of Computational Physics 404 (2020) 108973. doi:10.1016/j.jcp.2019.108973.

[20] T. Kadeethum, F. Ballarin, Y. Choi, et al., Non-intrusive reduced order modeling of natural convection in porous media using convolutional autoencoders: Comparison with linear subspace techniques, Advances in Water Resources 160 (2022) 104098. doi:10.1016/j.advwatres.2021.104098.

[21] J. Barnett, C. Farhat, Y. Maday, Neural-network-augmented projection-based model order reduction for mitigating the Kolmogorov barrier to reducibility, Journal of Computational Physics 492 (2023) 112420. doi:10.1016/j.jcp.2023.112420.

[22] N. Lepage, S. Beneddine, C. Fiorini, et al., Hybrid AutoEncoder/Galerkin approach for nonlinear reduced or-

der modelling, Computers & Fluids 302 (2025) 106811. doi:10.1016/j.compfluid.2025.106811.

[23] N. R. Franco, A. Manzoni, P. Zunino, et al., Deep orthogonal decomposition: A continuously adaptive neural network approach to model order reduction of parametrized partial differential equations, Advances in Computational Mathematics 52 (2026) 31. doi:10.1007/s10444-026-10295-7.

[24] G. Négiar, M. W. Mahoney, A. S. Krishnapriyan, Learning differentiable solvers for systems with hard constraints, in: International Conference on Learning Representations, 2023, arXiv:2207.08675.

[25] G. de Vahl Davis, Natural convection of air in a square cavity: A bench mark numerical solution, International Journal for Numerical Methods in Fluids 3 (3) (1983) 249–264. doi:10.1002/fld.1650030305.

[26] P. Le Quéré, T. Alziary de Roquefort, Computation of natural convection in two-dimensional cavities with Chebyshev polynomials, Journal of Computational Physics 57 (2) (1985) 210–228. doi:10.1016/0021-9991(85)90043-9.

[27] P. Le Quéré, Accurate solutions to the square thermally driven cavity at high Rayleigh number, Computers & Fluids 20 (1) (1991) 29–41. doi:10.1016/0045-7930(91)90025-D.